

UNIVERSIDADE DE PASSO FUNDO
Programa de Pós-Graduação em
Computação Aplicada

Dissertação de Mestrado

**SISTEMA PARA DETECÇÃO DE
DESOXINIVALENOL EM GRÃOS DE
TRIGO POR ANÁLISE
MULTIESPECTRAL**

DEIVIDI FELIPE ZAIONS



UNIVERSIDADE DE PASSO FUNDO
INSTITUTO DE CIÊNCIAS EXATAS E GEOCIÊNCIAS
PROGRAMA DE PÓS-GRADUAÇÃO EM COMPUTAÇÃO APLICADA

**SISTEMA PARA DETECÇÃO DE
DESOXINIVALENOL EM GRÃOS DE TRIGO
POR ANÁLISE MULTIESPECTRAL**

Deividi Felipe Zaions

Dissertação apresentada como requisito parcial à obtenção do grau de Mestre em Computação Aplicada na Universidade de Passo Fundo.

Orientador: Prof. Dr. Carlos Amaral Hölbig

Coorientador: Prof. Dr. Willingthon Pavan

Passo Fundo

2023

CIP – Catalogação na Publicação

Z21s Zaions, Deividi Felipe

Sistema para detecção de desoxinivalenol em grãos de trigo
por análise multiespectral / Deividi Felipe Zaions. – 2023.
57 f. : il. ; 30 cm.

Orientador: Prof. Dr. Carlos Amaral Hölbíg.

Coorientador: Prof. Dr. Willingthon Pavan.

Dissertação (Mestre em Computação Aplicada) –
Universidade de Passo Fundo, 2023.

1. Desoxinivalenol. 2. Espectroscopia NIR. 3. Sensor multi-
espectral. 4. Redes neurais. I. Hölbíg, Carlos Amaral,
orientador. II. Pavan, Willingthon, coorientador. III. Título.


CDU: 004.4

Catalogação: Bibliotecário Luís Diego Dias de S. da Silva – CRB 10/2241


ATA DE DEFESA DO TRABALHO DE CONCLUSÃO DE CURSO DO ACADÊMICO

DEIVIDI FELIPE ZAIONS


Aos vinte e três dias do mês de março do ano de dois mil e vinte e três, às quinze horas, realizou-se, no auditório do Prédio B5 do Campus 1 da UPF, a sessão pública de defesa do Trabalho de Conclusão de Curso “Sistema de baixo custo para detecção de Desoxinivalenol em grãos de trigo por análise multiespectral”, de autoria de Deividi Felipe Zaions, acadêmico do Curso de Mestrado em Computação Aplicada do Programa de Pós-Graduação em Computação Aplicada – PPGCA. Segundo as informações prestadas pelo Conselho de Pós-Graduação e constantes nos arquivos da Secretaria do PPGCA, o aluno preencheu os requisitos necessários para submeter seu trabalho à avaliação. A banca examinadora foi composta pelos doutores Carlos Amaral Hölbig, Willingthon Pavan, Alexandre Lazaretti Zanatta e José Mauricio Cunha Fernandes. Concluídos os trabalhos de apresentação e arguição, a banca examinadora considerou o candidato **APROVADO**. Foi concedido o prazo de até quarenta e cinco (45) dias, conforme Regimento do PPGCA, para o acadêmico apresentar ao Conselho de Pós-Graduação o trabalho em sua redação definitiva, a fim de que sejam feitos os encaminhamentos necessários à emissão do Diploma de Mestre em Computação Aplicada. Para constar, foi lavrada a presente ata, que vai assinada pelos membros da banca examinadora e pela Coordenação do PPGCA.




Prof. Dr. Carlos Amaral Hölbig - UPF
Presidente da Banca Examinadora (Orientador)




Prof. Dr. Willingthon Pavan - UPF
(Coorientador)



Prof. Dr. Alexandre Lazaretti Zanatta - UPF
(Avaliador Interno)



Dr. José Mauricio Cunha Fernandes - Embrapa Trigo
(Avaliador Externo)



Prof. Dr. Carlos Amaral Hölbig - UPF
(Coordenador do PPGCA)

SISTEMA PARA DETECÇÃO DE DESOXINIVALENOL EM GRÃOS DE TRIGO POR ANÁLISE MULTIESPECTRAL

RESUMO

Desonivalenol é uma das micotoxinas mais comumente encontradas em grãos de trigo em decorrência de sua contaminação pelo fungo *Fusarium*. Sua ingestão ocasiona efeitos tóxicos, causando risco à saúde humana e animal, assim como a perda de valor econômico em diversas produções. Dessa forma, o desenvolvimento de técnicas rápidas e robustas para a identificação dessa micotoxina no início da cadeia produtiva é de suma importância para a garantia alimentar global. Técnicas não destrutivas, baseadas em espectroscopia no infra-vermelho próximo (NIR - *Near-Infrared*), têm se demonstrado promissoras para a detecção da contaminação de DON em grãos de trigo. Contudo, os estudos recentes utilizam equipamentos hiper-espectrais por imagem de alto custo para a coleta de dados. Em decorrência disso, são necessários complexos modelos matemáticos e um processamento dispendioso para a identificação da contaminação por DON. Esse trabalho tem por objetivo o desenvolvimento de um sistema multiespectral para a identificação da micotoxina DON em grãos de trigo. Para isso, projeta-se um sistema portátil utilizando sensores multiespectrais que operam dentro do espectro visível e NIR, capaz de comunicar-se com um dispositivo móvel (*smartphone*). Desenvolve-se então dois algoritmos com base em redes neurais, um para regressão e outro para decisão binária entre amostras saudáveis e contaminadas, e uma aplicação *mobile* para receber os dados espectrais do sensor e processar junto aos algoritmos. Para o treinamento, teste e validação do sistema proposto, utiliza-se de um total de 117 amostras com diferentes níveis de contaminação e 84 amostras sadias. Por meio dos resultados obtidos, verificou-se que o algoritmo de regressão não apresentou acurácia suficiente para indicação dos níveis de contaminação. Por outro lado, a partir da combinação entre o algoritmo binário e a adaptação do algoritmo de regressão para decisão binária, o sistema apresentou uma acurácia R^2 de 0,855 para a identificação das amostras. Com isso, pôde-se concluir que sensores multiespectrais que operam na região visível e NIR são capazes da identificação de contaminação por DON em grãos de trigo.

Palavras-Chave: desoxinivalenol, espectroscopia NIR, sensor multi-espectral, redes neurais.

DEOXYNIVALENOL DETECTION SYSTEM IN WHEAT GRAINS BY MULTISPECTRAL ANALYSIS

ABSTRACT

Deoxynivalenol is one of the most commonly mycotoxins found in wheat grains due to *Fusarium* contamination. Its ingestion causes toxic effects, causing risk to both human and animal health, as well as the loss of economic value. Thus, the development of fast and robust techniques to the identification of this mycotoxin at the beginning of the production chain is of utmost importance for global food security. Non-destructive techniques based on near-infrared (NIR) spectroscopy have shown promising prospects for the detection of DON contamination in wheat grains. However, recent studies use high-cost hyperspectral imaging equipment for data collection. As a result, complex mathematical models and high demanding processing are required to identify DON contamination. This work aims to develop a multispectral system for the identification of DON mycotoxin in wheat grains. Using multispectral sensors that operate within the visible and NIR spectrum, a portable system capable of communicating with a mobile device (smartphone) is designed. Two algorithms based on neural networks are then developed, one for regression and the other for binary decision between healthy and contaminated, and a mobile application to receive the spectral data from the sensor and process it together with the algorithms. For training, testing and validation of the proposed system it is used a total of 117 samples with different levels of contamination and 84 healthy samples. Through the obtained results it is checked that the regression algorithm did not show sufficient accuracy to indicate the levels of contamination. On the other hand, from the combination between the binary algorithm and the adaptation of the regression algorithm for binary decision, the system presented an accuracy R^2 of 0.855 for the identification of healthy and contaminated samples. With this, we could conclude that multispectral sensors operating in the visible and NIR region are capable of identifying DON contamination in wheat grains.

Keywords: deoxynivalenol, NIR spectroscopy, multispectral sensor, neural networks.

LISTA DE FIGURAS

Figura 1	–	Histórico de área, produção, consumo e estoque finais mundiais de trigo entre as safras de 1987/88 à 2022/23 [20].	14
Figura 2	–	Doenças no trigo.	15
Figura 3	–	Componentes, interações e fatores para doenças no trigo [25]. . .	16
Figura 4	–	Contaminação por fusariose em espigas de trigo [35].	18
Figura 5	–	Distribuição espacial de níveis de DON em amostras comerciais de trigo obtidas no período de 2009 à 2017 [36].	19
Figura 6	–	Estrutura química da micotoxina desoxinivalenol.	19
Figura 7	–	Parte do espectro eletromagnético [42].	21
Figura 8	–	Abordagem típica para métodos de ML [60].	26
Figura 9	–	Categorização de algoritmos de ML.	26
Figura 10	–	Composição típica de uma rede neural com duas camadas.	27
Figura 11	–	Diagrama de utilização do <i>framework</i> Tensorflow Lite [66].	29
Figura 12	–	Amostras de trigo.	30
Figura 13	–	Sensor multiespectral AS72651.	31
Figura 14	–	Características ópticas dos sensores AS7265X.	31
Figura 15	–	Diagrama do módulo AS7265X.	32
Figura 16	–	Módulo de desenvolvimento AS7265X DEV MODULE.	33
Figura 17	–	Curvas da resposta espectral dos LEDs L1SP-PNK1002800000, L1SP-FRD0002800000 e SIR67-21C/TR8.	34
Figura 18	–	Esboço da montagem mecânica do dispositivo de leitura multiespectral.	34
Figura 19	–	Desenho técnico das peças impressas 3D.	35
Figura 20	–	Peças impressas 3D.	35
Figura 21	–	Montagem do dispositivo.	36
Figura 22	–	Peças de calibração.	36
Figura 23	–	Cabo de conexão USB OTG e conversor USB-Serial.	37
Figura 24	–	Aplicativo móvel para conexão com sistema multiespectral.	40
Figura 25	–	Sistema de coleta e processamento de dados multiespectrais.	40
Figura 26	–	Linha de referência para gráficos de correlação.	41
Figura 27	–	Matriz de confusão padrão para análise dos dados.	42

Figura 28	–	Correlação entre valores de contaminação verdadeiros e preditos das amostras de teste para o modelo de regressão.	44
Figura 29	–	Distribuição do erro absoluto entre a previsão do algoritmo e o valor verdadeiro de contaminação nas amostras de teste.	44
Figura 30	–	Evolução da acurácia para amostras de teste para o modelo binário.	45
Figura 31	–	Matriz de confusão para o teste de amostras com o algoritmo binário.	45
Figura 32	–	Resultado do modelo ANN de regressão.	47
Figura 33	–	Resultado do modelo ANN de regressão.	48

LISTA DE TABELAS

Tabela 1	–	Limites Máximos Tolerados para a micotoxina DON no Brasil	20
Tabela 2	–	Principais especificações disponibilizadas por fabricantes comerciais de espectrômetros portáteis VNIR [48]	24
Tabela 3	–	Composição das ANNs.	39
Tabela 4	–	Desempenho do algoritmo de regressão para amostras de teste. .	43
Tabela 5	–	Desempenho do algoritmo de binário para amostras de teste.	46
Tabela 6	–	Desempenho do algoritmo de regressão para amostras de validação.	46
Tabela 7	–	Desempenho do algoritmo de binário em conjunto com o de regressão para amostras de validação.	49

SUMÁRIO

1	INTRODUÇÃO	11
2	REVISÃO BIBLIOGRÁFICA	13
2.1	TRIGO	13
2.1.1	Doenças no trigo	14
2.2	MICOTOXINAS	15
2.2.1	Desoxinivalenol	17
2.2.2	Legislação	19
2.3	ESPECTROSCOPIA	20
2.3.1	Princípios da Espectroscopia do Visível e Infravermelho Próximo	20
2.3.2	Sensores espectrais	22
2.4	MACHINE LEARNING	25
2.4.1	Redes Neurais Artificiais	27
2.4.2	TensorFlow	28
2.4.2.1	TensorFlow Lite	28
3	MATERIAL E MÉTODOS	30
3.1	AMOSTRAS DE TRIGO	30
3.2	HARDWARE	31
3.2.1	Sensor Multiespectral	31
3.2.2	Montagem Eletrônica	32
3.2.3	Sistema de Iluminação	33
3.2.4	Montagem Mecânica	33
3.2.5	Calibração	35
3.2.6	Dispositivo Móvel	36
3.3	SOFTWARE	37
3.3.1	TensorFlow	37

3.3.2	Algoritmo ANN	38
3.3.3	Aplicação Mobile	38
3.4	PROCEDIMENTO DE COLETA E PROCESSAMENTO DOS DADOS.....	39
4	RESULTADOS E DISCUSSÕES	41
4.1	TREINAMENTO E TESTE	43
4.2	VALIDAÇÃO	46
5	CONCLUSÕES E TRABALHOS FUTUROS	51
	Referências	52

1. INTRODUÇÃO

O trigo e seus derivados são amplamente consumidos mundialmente, tendo um papel de grande importância na cadeia alimentar, assim como na economia global de alimentos. Seu uso atende não somente a indústria alimentícia humana, mas também tem importante participação na formulação de rações para a cadeia produtiva animal. Dessa forma, a qualidade e segurança nutricional deste cereal vem ganhando maior espaço de atenção tanto na indústria quanto na academia.

Dentre os fatores que influenciam no valor econômico do trigo estão os patógenos que acometem os grãos em determinados momentos de sua cadeia de produção. *Fusarium* é um patógeno bem conhecido e difundido nesse meio, responsável por uma série de doenças. Dentre esse grupo patógeno, destaca-se o *Fusarium graminearum* em seu estado anamorfo, também conhecido como *Gibberella zeae*. Nesse estado, esse fungo é capaz de gerar a doença chamada giberela. Sob certas condições, essa doença tem a capacidade de produzir micotoxinas, tais como nivalenol (NIV), zearalenone (ZEA) e desoxinivalenol (DON).

A contaminação por DON tem graves efeitos tanto na alimentação humana quanto animal. Para pessoas, uma alta ingestão de DON pode causar anorexia, náuseas e vômito. Pesquisas demonstram que sua ingestão periódica e constante, por sua vez, pode causar doenças auto-imunes e câncer. Também, a ingestão dessa micotoxina por animais, está associada com problemas na alimentação, náuseas, vômitos e perda de peso [1]. Devido sua estrutura altamente estável, o DON pode suportar os estágios de armazenamento, processamento, congelamento, cozimento e tosta, perdurando até o consumo [2].

A maior parte dos países já estabeleceu limites máximos permitidos sobre a concentração de DON em alimentos. A Comissão Europeia definiu diferentes níveis de concentração de DON permitidos de acordo com o estado do cereal, sendo, por exemplo, 750 $\mu\text{g/kg}$ para cereais de consumo humano direto, 500 $\mu\text{g/kg}$ para pães, biscoitos, massas, entre outros, e 200 $\mu\text{g/kg}$ para comidas baseadas em cereais para bebês e crianças [3]. Por sua vez, a legislação brasileira indica um nível máximo para contaminação por DON de 750 $\mu\text{g/kg}$ para produtos gerais processados, como pães, biscoitos, crackers, produtos de panificação, entre outros, e também 200 $\mu\text{g/kg}$ para comidas baseadas em cereais para bebês e crianças [4].

Atualmente, existem várias técnicas para a identificação da presença de DON em grãos de trigo. A metodologia mais comum é a partir de análises químicas, como LC-MS/MS (*Liquid Chromatography-Mass Spectrometry*), HPLC (*High-Performance Liquid Chromatography*), GC (*Gas Chromatography*) e ELISA (*Enzyme-Linked Immunosorbent Assays*) [5],[6],[7] e [8]. Embora essas técnicas tenham um elevado nível de acurácia na determi-

nação do grau de contaminação por DON, são técnicas destrutivas, requerem profissionais treinados e uma complexa preparação das amostras, tornando-as morosas e exigindo processos e equipamentos específicos. Devido a isso, técnicas mais rápidas e eficientes são demandadas para identificar a contaminação por DON em grãos de trigo antes de sua entrada na cadeia de produção.

Técnicas não destrutivas e livres de análises químicas, como espectroscopia fluorescente, infra-vermelho (IR), infra-vermelho próximo (NIR), espectroscopia Raman, por imagem e sensores colorimétricos (CSA) são algumas técnicas que estão sendo investigadas na literatura como proeminentes sucessores para identificação de DON. Além dessas características, esses métodos são de simples execução, rápidos e não requerem uma preparação complexa das amostras [9]. Dentre eles, a espectroscopia NIR tem crescido e apresentado resultados positivos ([10], [11] e [12]).

A análise NIR é realizada por meio da aplicação de radiação no espectro de frequência do infravermelho próximo com diferentes comprimentos de onda, onde é possível avaliar de forma quantitativa e qualitativa os componentes de um organismo de acordo com as diferentes características de absorção e dispersão da luz. Quando um organismo é exposto a luz, a sua transmissão pelas moléculas depende da combinação dos efeitos de reflexão, dispersão e absorção. A reflexão está diretamente relacionada com o ângulo de entrada da luz na superfície, enquanto a dispersão e a absorção são propriedades que variam de acordo com o comprimento de onda da luz irradiante. A dispersão da luz no organismo é menor quando os comprimentos de ondas são maiores, tal característica favorece a transmissão do infravermelho próximo, visto que este possui maior comprimento de onda dentro do espectro da luz [13].

Nestas recentes abordagens, imagens hiper-espectrais tem sido utilizadas como a principal tecnologia para avaliações dentro do espectro NIR. Essas metodologias dependem de dispositivos de alto custo para a leitura espectral dos grãos de trigo, resultando em um grande volume de dados. Em decorrência disso, os processos matemáticos para a preparação dos dados para análise são complexos, demandando de alta carga computacional e, em sua maior parte, incluem uma estação fixa para realizar as leituras ([14], [15] e [16]).

Tendo em mente as adversidades das tecnologias utilizadas atualmente, o presente trabalho tem por objetivo o desenvolvimento um sistema multiespectral, portátil para a identificação da micotoxina DON em grãos de trigo. Para isso, esse trabalho seleciona um sensor capaz de realizar leituras no espectro NIR e de realizar a comunicação com dispositivos móveis, apresentando o desenvolvimento de uma rede neural artificial para o processamento e previsão da contaminação por DON em grãos de trigo.

2. REVISÃO BIBLIOGRÁFICA

Este capítulo tem por objetivo introduzir assuntos importantes para a compreensão do trabalho. É apresentado inicialmente o objeto do estudo que foi o trigo, as micotoxinas desta espécie e a legislação que define os níveis aceitáveis de contaminação. Em seguida são descritos os conceitos e aplicações da espectroscopia e de *machine learning*, aplicados aos métodos nesta pesquisa.

2.1 TRIGO

O trigo é um dos cereais com cultivo mais antigo na história da humanidade, tendo registro do seu plantio há cerca de 10.000 anos A.C., na Mesopotâmia. No decorrer da história da humanidade, diversas civilizações utilizaram o trigo como base de alimentação, desenvolvendo pães, biscoitos e massas, sendo hoje fundamental para a alimentação humana e animal [17].

Atualmente cerca de 20% das calorias consumidos pelo homem em sua alimentação provém do trigo, que, além disso, contém glúten, uma proteína indispensável para muitos alimentos. O trigo é largamente utilizado em seus derivados imediatos, como farinhas (branca e integral) e triguinho. A partir das farinhas do trigo, são preparados pães e massas. O farelo de trigo é adicionado diariamente a mingaus, sopas e outros alimentos, assim como também utilizado como ração para bovinos, suínos e aves [18].

Para o ano de 2021, o consumo mundial de trigo foi estimado em 784,8 milhões de toneladas, com um estoque de 289,64 milhões de toneladas. A relação do estoque/consumo entre os anos de 2020 e 2021 reduziu em 2,6 %, demonstrando a crescente demanda mundial pelo cereal. Para a safra global 2021/2022, estima-se uma produção de 779,03 milhões de toneladas e um crescimento de 0,62 % na área plantada, onde atualmente encontra-se atualmente em 220,83 milhões de hectares [19]. A evolução na área de plantio, produção, consumo e estoque mundiais entre as safras de 1987/88 à 2022/23 podem ser visualizadas na Figura 1.

No Brasil, o trigo foi trazido por Martim Afonso de Souza em 1534. Contudo, apresentou dificuldades de cultivo devido ao clima quente nas primeiras regiões colonizadas. Na segunda metade do Século XVIII a cultura do trigo começou a ser desenvolvida no Rio Grande do Sul, entretanto a ferrugem dizimou os trigais no começo do século XIX. No século XX, as plantações foram retomadas, sendo expandidas no Rio Grande do Sul e Paraná a partir dos anos de 1940. [17].

Desde então o trigo se tornou uma cultura de ampla produção no país, principalmente na região sul. A área de cultivo nacional cresceu 16,3% sobre a da temporada 2020,




Figura 1. Histórico de área, produção, consumo e estoque finais mundiais de trigo entre as safras de 1987/88 à 2022/23 [20].

atingindo 2,72 milhões de hectares. Por sua vez, produtividade foi estimada em 2,868 toneladas por hectare, apresentando também um crescimento de 7,7% em relação ao ano de 2020 [21]. Atualmente, o Brasil é o 15º maior produtor de trigo, com previsão estimada de 8,5 milhões de toneladas de trigo na safra 2021/22, segundo o USDA [20].

2.1.1 Doenças no trigo

Com os avanços tecnológicos, a produtividade do setor de grãos brasileiro cresceu significativamente nas últimas décadas. Com isso, a demanda atual de mercado está relacionada com a gestão de qualidade, rastreabilidade e certificação do sistema de produção, visto que estes pontos impactam diretamente na segurança dos alimentos, aplicação e valor do material [22].

Perdas qualitativas e quantitativas na pós-colheita, decorrentes de contaminações, problemas no direcionamento e armazenamento de grãos, comprometem a eficiência e qualidade do processo de produção. Entre os principais fatores a serem observados para cultivares de trigo para reduzir perdas, podem-se destacar a determinação do índice de perda de peso, a implementação de boas práticas de armazenamento, a determinação de indicadores de qualidade tecnológica, a promoção e adoção de novas tecnologia e o diagnóstico da presença de contaminantes [23].

De acordo com o Ministério da Agricultura, Pecuária e Abastecimento (Mapa) e pela Organização das Nações Unidas para Agricultura e Alimentação (FAO) as perdas quantitativas representam em torno de 10 % da produção anual de grãos.

Por sua vez, as perdas qualitativas, com redução na classificação da finalidade dos grãos, apresenta prejuízos de difícil definição. Perdas no valor direto do produto podem chegar de 25 % a 50 %, além de comprometer a segurança alimentar com doenças e contaminações [24].

Dentre as principais causas das perdas qualitativas e quantitativas no trigo estão as doenças. Pode-se dividir a origem das doenças de acordo com fatores bióticos e abióticos. Fatores abiótico são as doenças causadas por fatores físicos e químicos, tais como excesso de nutrientes, luz ou água na planta. Por outro lado, doenças bióticas tem sua origem a partir das ações de outros seres vivos, tais como vírus, bactérias e fungos. Na Figura 2 representa-se algumas doenças no trigo.




Figura 2. Doenças no trigo.

O advento das doenças bióticas dependem de uma série de condições. Em um mesmo momento, patógeno e hospedeiro devem se encontrar, seja por partículas virais, células bacterianas ou esporos fúngicos. Além disso, patógenos tem maior afinidade com certos tecidos e órgãos do hospedeiro, fazendo com que diferentes doenças sejam promovidas de acordo com cada estágio do crescimento da planta. Por fim, fatores climáticos interferem na evolução e progresso dos patógenos. Com isso, o clima presente na região deve favorecer a maior ocorrência de certas doenças. A relação entre o patógeno, hospedeiro e o ambiente para a origem e evolução de doenças no trigo são expostos na Figura 3 [25].

2.2 MICOTOXINAS

As micotoxinas são metabólitos secundários, definidos como um produto provindos de fungos filamentosos, os quais são capazes de causar intoxicações, doenças e morte em




Figura 3. Componentes, interações e fatores para doenças no trigo [25].

humanos e animais. O termo micotoxina foi primeiramente utilizado na década de 1960 para descrever uma toxina associada com a contaminação de grãos de amendoins e na perda de aproximadamente 100 mil aves em uma criação de perus na Inglaterra. Essa micotoxina foi identificada posteriormente como *Aspergillus flavus* aflatoxina B1 [26].

Como um processo adicional de contaminação, as micotoxinas são um desafio para a área da saúde e vigilância sanitária. A sua presença é influenciada por uma série de fatores, dentro deles, pode-se citar os fatores biológicos, os quais abrangem a susceptibilidade da planta a contaminações por fungos; fatores da colheita, tratando-se da temperatura, umidade, danos mecânicos, danos por insetos, pássaros e a presença de fungos; fatores ambientais, considerando a maturação do vegetal, sua temperatura e umidade; e fatores de armazenamento, quanto aos processos de distribuição e processamento, tendo em vista a temperatura e umidade do grão dentro destes estágios [27].

Micotoxinas que tiveram sua estrutura alterada na planta, denominadas de micotoxinas conjugadas (mascaradas), apresentam um grande risco devido à dificuldade na aplicação de métodos de detecção. Atualmente, identificaram-se aproximadamente 500 espécies de micotoxinas. Estima-se que cerca de outras 1000 espécies ainda devem ser descobertas [28]. Alguns métodos convencionais, como ELISA (*Enzyme Linked Immunosorbent Assay*), podem ser capazes de responder à estas micotoxinas mascaradas. Contudo, outros métodos, por exemplo, baseados em HPLC (*High-Performance Liquid Chromatography*), apresentam maior dificuldade [29].

Embora possam-se encontrar diversas toxinas geradas na natureza, as principais toxinas são aquelas que acometem cereais de amplo consumo, como trigo, milho, arroz, entre outros. A fonte dessas toxinas que contaminam esses cereais são, principalmente, a família de fungos *Fusarium* e *Aspergillus*. Tais fungos são responsáveis pelas toxinas desoxinivalenol, nivalenol, zearalenone, ocratoxinas, fumonisinas e aflatoxinas [30].

A contaminação causada por micotoxinas é denominada de micotoxicose. No corpo humano, os órgãos mais afetados são o fígado, os rins, o cérebro, os músculos e o sistema nervoso. Os principais sintomas da contaminação são náuseas e vômitos, podendo ocorrer falta de coordenação dos movimentos (ataxia), e em alguns casos levar à morte. A intoxicação ocorre de forma direta, por meio da ingestão de alimentos contaminados por humanos ou animais; ou de forma indireta, quando animais se alimentam de subprodutos contaminados transferindo as toxinas para o leite/a carne, sendo a contaminação direta mais frequente.

Com isso, de acordo com o relatório anual do *Rapid Alert System for Food and Feed* (RASFF), da União Europeia, as micotoxinas apresentam-se como uma das principais ameaças notificadas para rejeição da entrada de alimentos na fronteira, onde 400 casos foram reportados em 2020. Embora houve uma queda de 23 % no número de casos notificados em relação ao ano anterior, o relatório aponta as dificuldades de trabalho de fiscalização causadas pela pandemia por COVID-19 como o motivo principal desta redução [31]. Estima-se que, na ausência de genótipos de trigo mais resistentes, o problema das micotoxinas receba maior importância em um futuro próximo devido a alguns fatores, tais como: mudanças climáticas; disseminação e alteração na população de fungos toxigênicos e resistência dos fungos aos fungicidas [32].

Algumas medidas são importantes para prevenir a presença de micotoxinas nos grãos e subprodutos, como: adotar manejo integrado de doenças e pragas a produção e pós colheita; realizar de forma rápida e eficiente a secagem dos grãos no recebimento e armazenamento; estabelecer monitoramento no manejo e logística dos lotes de grãos além de utilizar informações de modelagem de sistemas [33].

2.2.1 Desoxinivalenol

Descoberta no Japão, a micotoxina desoxinivalenol (DON) é gerada principalmente pelos fungos *Fusarium graminearum* e *Fusarium culmorum*. Esses fungos são comumente encontrados em grãos de pequeno porte, especialmente trigo e cevada. Diferente de outras micotoxinas que ocorrem durante estresse hídrico, o DON é gerado a partir do excesso de umidade. Isso ocorre principalmente em climas temperados, com baixas temperaturas e alta incidência de chuvas no período de florescimento, onde a contaminação por fusariose na espiga é estimulada (Figura 4) [34].

Devido a isso, a sua presença na região Sul do Brasil é mais destacada. A partir de uma análise de 1.000 amostras comerciais coletadas nesta região, no período de 2009 à 2017, detectou-se a micotoxina DON com a concentração acima de 1.000 $\mu\text{g/kg}$ em 36 % das amostras. Destaca-se que, no Rio Grande do Sul, a média da concentração de DON nas amostras foi de 1.500 $\mu\text{g/kg}$. A distribuição espacial dos níveis de DON destas amostras é demonstrada a partir da Figura 5 [36].



Figura 4. Contaminação por fusariose em espigas de trigo [35].

De acordo com sua estrutura (Figura 6), identifica-se DON como um composto orgânico polar que pertence a classe dos tricotecenos do grupo B. Sua toxicidade está associada aos seus três grupos livres de hidroxilas, caracterizada por causar vários sintomas, tais como diarreia, vômito, anorexia, redução de ganho de peso, alterações imunológicas e neuroendócrinas, hemorragia, leucocitose, choque circulatório, entre outras [37].

Dentre suas principais características físico-químicas, sua capacidade de resistir a altas temperaturas aumenta seu risco de ocorrência em alimentos. O DON apresenta grande estabilidade dentro de temperaturas de 170 °C a 350 °C, onde pode-se observar sua permanência mesmo durante a fritura de alimentos em óleo. Contudo, nota-se a redução dos níveis de DON em massas cozidas devido a lixiviação das moléculas de DON para a água do cozimento [38].

O controle da doença fúngica, sendo a giberela a mais recorrente, é uma alternativa para redução da incidência de DON nas espigas de trigo. Atualmente, há três estratégias de controle disponíveis, sendo elas: o manejo cultural; cultivares resistentes à doença; a aplicação de fungicidas. As maiores dificuldades destas estratégias levam em consideração que, para o manejo cultural, a dispersão da doença por esporos no ar permitem a proliferação com as condições climáticas adequadas, no qual não se possui controle direto. Os genes de novos cultivares não apresentam resistência completa à doença. O controle químico por fungicidas tem a barreira física da conformação das espigas para poder atingir o patógeno. Contudo, genes de resistência dissecados e introgrididos em linhagens de elite apresentam maior resistência à doença e/ou acúmulo de DON. Também, a aplicação de novos fungicidas junto à momentos mais adequados do desenvolvimento da planta, tendo em mente os momentos mais propícios para o desenvolvimento da doença, tem reduzido expressivamente a contaminação [39].




Figura 5. Distribuição espacial de níveis de DON em amostras comerciais de trigo obtidas no período de 2009 à 2017 [36].




Figura 6. Estrutura química da micotoxina desoxinivalenol.

2.2.2 Legislação

Devido sua característica termoestável, o DON não pode ser destruído pelo calor. Além disso, por ter sua origem natural em fungos amplamente distribuídos na natureza, não pode-se eliminá-lo completamente dos alimentos. Tendo isso em vista, o monitoramento de sua concentração em grãos e seus derivados atendendo a limites máximos estabelecidos é de suma importância para a segurança alimentar.

Tendo isso em mente, com a finalidade da proteção da saúde humana e animal, assim como assegurar valores econômicos, muitos países determinam Limites Máximos Tolerados (LMT) para a contaminação de micotoxinas em alimentos. Para o Brasil, a Agência

Nacional de Vigilância Sanitária (Anvisa) publicou em 18 Fevereiro de 2012 a Resolução da Diretoria Colegiada - RDC nº 7, a qual iniciou um controle gradativo sobre os limites máximos para contaminação de DON em grãos e produtos à base de trigo, tais como trigo integral, farinha, farelo, pães, massas e biscoitos. Publicada em 2017, a RDC nº 138 estabelece os LMTs que estão em vigor atualmente. Os Limites Máximos Tolerados para a micotoxina DON em grãos de trigo e seus derivados podem ser observados na Tabela 1.

Tabela 1. Limites Máximos Tolerados para a micotoxina DON no Brasil

Alimentos	LMT ($\mu\text{g/kg}$)
Trigo em grãos para posterior processamento	3000
Trigo integral, trigo para quibe, farinha de trigo integral, farelo de trigo, farelo de arroz, grão de cevada	1000
Farinha de trigo, massas, crackers, biscoitos de água e sal, e produtos de panificação, cereais e produtos de cereais exceto trigo e incluindo cevada malteada	750
Alimentos a base de cereais para alimentação infantil	200

2.3 ESPECTROSCOPIA

As ondas eletromagnéticas interagem com moléculas dos mais diversos meios, tais interações podem gerar diferentes fenômenos a partir da sua absorção, reflexão ou dispersão. Ondas de infra-vermelho aquecem a superfície da Terra, ondas de radiofrequência transmitem informação e as micro-ondas são capazes de cozinhar nossos alimentos. A lista de aplicações segue para inúmeros outros casos [40].

A Espectroscopia é definida como o conjunto de técnicas que estuda e avalia as moléculas com base nestas interações nas diferentes frequências do espectro eletromagnético, possibilitando o desenvolvimento de aplicações utilizando ondas eletromagnéticas, como citadas anteriormente. Este trabalho utiliza de tais técnicas para a análise de contaminação da micotoxina desoxinivalenol em grãos de trigo.

2.3.1 Princípios da Espectroscopia do Visível e Infravermelho Próximo

As ondas eletromagnéticas tem comportamentos distintos nas diferentes regiões do seu espectro. Sua transmissão não depende de um meio, podendo-se propagar pelo vácuo. Formada por um campo elétrico e magnético oscilante perpendiculares um ao outro, apresenta sua frequência inversamente proporcional ao seu comprimento [41]. Essa relação é dada pela Equação 1.

$$\nu = \frac{c}{\lambda} \quad (1)$$

onde ν é a frequência, c é a velocidade da luz e λ é o comprimento da onda eletromagnética.

A energia, por sua vez, é diretamente proporcional a frequência, obtida a partir da Equação 2.

$$E = h\nu \quad (2)$$

onde E é a energia e h é a constante de Planck.

Dessa forma, pode-se observar que quanto maior a frequência da onda eletromagnética, maior sua energia. Um trecho do espectro eletromagnético, separando em camadas de acordo com a intensidade de energia propagada, é indicado na Figura 7.




Figura 7. Parte do espectro eletromagnético [42].

As ondas eletromagnéticas do espectro visível e do infravermelho próximo (NIR - *Near Infrared*) têm a capacidade de causar transições de energia eletrônicas e vibracionais, respectivamente. As ondas visíveis encontram-se no espectro variando entre 400 nm à 800 nm. O infravermelho próximo, chamado desta forma por estar próximo ao espectro visível, é caracterizado pela combinação de ondas curtas com 700 a 1.400 nm e bandas de vibração de 1.400 a 2.500 nm [42].

As formas em que ocorrem as vibrações estão diretamente relacionadas ao número de ligações e átomos que a molécula contém, sendo que cada componente possui característica de absorção única. Dessa forma, as moléculas só conseguem absorver radiação infravermelha se ocorrer uma mudança no momento dipolo, quando a frequência da radiação emitida for igual à frequência vibracional das moléculas [43].

A forte atuação de métodos NIR em segmentos que envolvem materiais de composição majoritária em matéria orgânica e em menor fração inorgânica não é casual. As ligações orgânicas têm bandas de absorção na região do infravermelho próximo, enquanto que os minerais só são detectados quando em complexos orgânicos ou quelatos. Isso ocorre devido à baixa massa atômica do hidrogênio, onde as harmônicas e combinações

de banda do hidrogênio fazem com que os grupos funcionais C-H, O-H e NH sejam dominantes no espectro do infravermelho próximo em alimentos, com comprimentos de onda de absorção específicos [44].

Contudo, na região do NIR ocorre a sobreposição de ondas eletromagnéticas em diferentes moléculas. Com isso, certas frequências são absorvidas ou refletidas por mais de um composto químico. Esse é um fenômeno comum e, devido a isso, picos e vales de absorção ou reflexão eletromagnéticas de materiais na região VIS-NIR não podem ser considerados como determinantes para identificação da composição química. As ligações mais comuns para observar-se esse fenômeno são, por exemplo, C-H, N-H, O-H e S-H [44].

2.3.2 Sensores espectrais

A primeira faixa do espectro eletromagnético não visível a ser identificada foi o infravermelho próximo (NIR), em 1800 por Sir William Herschel [45]. Contudo, as primeiras aplicações analíticas foram desenvolvidas cerca de um século e meio após sua descoberta, pois neste período existia uma dificuldade de interpretação dos espectros NIR pelas suas inúmeras bandas de absorção fortemente sobrepostas. Sua disseminação no mundo acadêmico foi possível somente com o desenvolvimento de técnicas matemáticas para contornar a falta de seletividade dos espectros de absorção assim como a evolução dos instrumentos de medida.

Somente após a década de 1960 foram desenvolvidos espectrofotômetros comerciais capazes de obter um espectro com qualidade na região NIR. A partir da metade dos anos de 1970, a tecnologia NIR passou a ser amplamente aplicada tendo como base os fundamentos da espectroscopia vibracional, a instrumentação espectrofotométrica NIR e a quimometria [46].

Além disso, os contínuos avanços em termos de *hardware* e *software*, possibilitaram a coleta e tratamento de um grande número de dados de uma mesma amostra, o que viabilizou análises complexas de soluções e substâncias, ampliando as aplicações da tecnologia NIR. Os métodos analíticos qualitativos e quantitativos baseados em espectroscopia NIR tem aumentado sua relevância com a incorporação em diversas áreas do setor produtivo e também por meio da publicação de normas oficiais elaboradas para guiar desenvolvimento, validação e manutenção destes métodos [47].

Atualmente, encontra-se uma variedade de soluções de sensores espectrais atuando nas bandas VNIR no mercado. Conforme apresentado em [48], pode-se dividir esses instrumentos em quatro categorias: instrumentos dedicados; instrumentos para processos; instrumentos miniaturizados e de mão; instrumentos baseados em imagens hiper-espectrais e imagens.

Os instrumentos dedicados tem por objetivo a análise específica de certos materiais utilizando um grupo pré-selecionado de ondas eletromagnéticas. Esses métodos geralmente fazem uso de filtros e/ou LEDs (*Ligth Emmiting Diodes*) para controlar a banda eletromagnética sobre as amostras. Seu principal uso são em aplicações com alta demanda por dispositivos, tais como controle de qualidade de combustíveis ([49] e [50]). Com o passar dos anos, um maior número de sensores com bandas específicas de leitura tem sido lançados ao mercado e o desenvolvimento de LEDs que operaram na região NIR auxiliam o desenvolvimento deste tipo de instrumento ([51] e [52]).

Por sua vez, instrumentos para processo são parte fundamental para tecnologia analítica de processos (PAT - *Process Analytical Technology*). Dessa forma, esses instrumentos atuam como indicadores para parâmetros críticos de processos que afetam atributos de qualidade para as indústrias farmacêuticas, alimentícias, refinarias, petroquímicas, dentre outras ([53] e [54]). Esses equipamentos devem operar de forma autônoma a fim de assegurar a qualidade e padronização dos espectros analisados. Tanto os equipamentos quanto seus demais componentes relacionados ao processo de coleta de dados devem ser testados e validados para garantir medidas espectrais confiáveis. Dessa forma, diferentes tecnologias de equipamentos são utilizados de acordo com cada situação. Tempo de aquisição de medidas, resistência à intemperes e resistência à vibração são alguns dos fatores a serem considerados nas especificações desses instrumentos.

Sob outra perspectiva, os dispositivos miniaturizados e de mão tiveram um grande crescimento na última década. Diversos espectrômetros portáteis, de tamanho e custo reduzido, entraram no mercado e tem possibilitado medidas espectrais em campo. Pode-se observar na Tabela 2 uma lista de fabricantes e modelos de espectrômetros que operam no alcance VNIR. Cada fabricante opta por uma diferente comunicação de seu dispositivo, apresentando diferentes informações sobre suas características técnicas. Nem todos os dados observados foram listados pelos fabricantes.

Tabela 2. Principais especificações disponibilizadas por fabricantes comerciais de espectrômetros portáteis VNIR [48]

Fabricante	Modelo	Tecnologia	Resolução espectral (nm)	Alcance espectral (nm)	Deteção	Comunicação / Armazenamento	Alimentação/ Portátil?
Stellar Inc.	Red-Wave-Micro	MEMS	10	1750-2150	InGaAs	USB	Externo/Não
RGB Photonics	Q-Red	Fabry-Perot Czerny-Tuner Grating	4	900-1700	InGaAs	USB, Bluetooth e Proprietário	Externo/Não
Texas Instruments	NanoNIR	Grating - MEMS - DMD	10	900-1700	InGaAs	USB e Bluetooth/ Cartão de Memória	USB ou Bateria/ Sim
Viavi Solutions	MicroNIR OnSite	LVF - Linear Variable Filter	12-20	950-1650	InGaAs	USB	USB ou Bateria/ Sim
Young Green	NIR Scan	MEMS - DMD	10	900-1700	InGaAs	USB e Bluetooth/ Cartão de Memória	USB ou Bateria/ Sim
ASD Inc.	QualitySpec Trek	X	3-8	350-2500	X	X	Bateria/Sim
Panalytical Stratio Technology Inc.	Link Square	X	10	450-1000	X	Wi-Fi	Bateria/Sim
Si-Ware Systems	NeoSpectra	MEMS - Ff	8-16	1250-1700	InGaAs	USB	USB/Não
ConsumerPhysics	SCiO	X	X	X	X	Bluetooth	Bateria/Sim
Spectral Evolution	LF - 2500	Czerny-Turner	10-20	1000-2500	InGaAs	USB e Bluetooth	Externo/Não
IOR3 S.r.l	PoliSpec NIR	Concave Grating	2,2	900-1700	InGaAs	USB, RS232 e Bluetooth	Externo/Não
Brimrose	Luminar 5030	AOTF	1-10	900-1800	InGaAs	TCP IP e cabo I/O	Externo/Sim
ThermoFisher Scientific	MicroPhasir	Grating - MEMS Hadamard	11	900-1690	InGaAs	USB/ Interno	Bateria/Sim
ThorLabs	CCS 175	Grating	0,8	500-1000	CCD	USB	Externo/Não
Felix Instruments	F 750	Grating	8-13	310-1100	Si	Wi-Fi/ Interno	Bateria/Sim
Ocean Optics	Flame NIR	Grating	~10	950-1650	InGaAs	USB	Externo/Não
Xian Yima	NIRMagic	X	12,5	950-1650	X	USB/ Interno	Bateria/Sim
Optoelec. Co.. Ltd							
Spectral Engines	NIRONE 2.0	MEMS Fabry-Perot	16-2	1550-1950	InGaAs	USB e Bluetooth	Bateria/Sim

Por fim, os instrumentos baseados em imagem adicionam uma dimensão espacial às leituras espectrais. Também conhecido como HSI (*Hyper Spectral Imaging*), esses instrumentos fazem uso de câmeras hiper-espectrais que possibilitam uma análise mais profunda das amostras, avaliando a distribuição dos elementos que a compõem, com uma larga banda espectral. Seu uso tem se intensificado nos últimos anos, assim como os demais tipos de instrumentos previamente citados ([55] e [56]). Diferente das técnicas citadas anteriormente, onde um ponto único é avaliado nas amostras, essas câmeras hiper-espectrais capturam uma imagem da superfície da amostra, onde cada pixel que a compõem possui uma informação espectral. Dessa forma, o resultado disso é um hipercubo de 3 dimensões. O comprimento e largura são os dados espaciais da amostra e a sua altura corresponde a resposta espectral de cada pixel. A altura deve variar de acordo com a quantidade de bandas espectrais avaliadas pelo instrumento. O termo hipercubo é utilizado dado a grande quantidade de bandas espectrais analisadas [57].

2.4 MACHINE LEARNING

Com estudos que datam desde meados do século XX, o *machine learning* (ML), ou aprendizado de máquina, pode ser definido como uma área científica que possibilita para máquinas a habilidade de aprender sem ser diretamente programadas [58]. Nos tempos atuais, onde tecnologias como *big data* e computação de alta performance fazem parte do nosso cotidiano, técnicas de *machine learning* criam novas oportunidades para o descobrimento, quantificação e melhor compreensão do nosso ambiente e o que o compõem.

Essa revolução da informação chega também ao campo, onde termos como agricultura de precisão e *smart farms* incorporam técnicas de ML dentro do seu contexto. Com o uso de sensores inteligentes, tecnologias de *Internet of Things* (IoT), *Global System Positioning* (GPS), inteligência artificial (IA), entre outras, técnicas de ML podem ser utilizadas para a predição de propriedades do solo e condições climáticas, predição da produtividade da colheita, detecção de doenças e ervas daninhas, controle de irrigação por gotejamento, controle e produção pecuária, colheitas inteligentes, entre outras [59].

De um modo geral, o processo de aprendizado de um algoritmo de ML envolve dados de treinamento. Esses dados servem como uma base de experiência, tais como um conjunto de exemplos. Comumente, esses exemplos possuem um grupo de atributos, também reconhecidos como as variáveis que compõem o sistema. Essas variáveis podem ser nominais (enumerações), binárias (verdadeiros ou falsos) ou numéricas (inteiros, números reais, entre outros). A cada exemplo que o algoritmo processa, sua performance é melhorada, uma vez que passa a aprender com base em sua experiência. Após o treinamento do algoritmo, a partir dessas informações iniciais, pode-se utilizá-lo para classificar, prever ou agrupar um novo conjunto de dados [60]. A típica abordagem utilizada por métodos de ML é demonstrada a partir da Figura 8.




Figura 8. Abordagem típica para métodos de ML [60].

Os algoritmos de ML podem ser categorizados como aprendizado supervisionado, aprendizado não supervisionado e aprendizado por reforço. O aprendizado supervisionado utiliza dados de entrada e saída identificados para seu processo de aprendizagem. Dessa forma, o algoritmo vincula os dados de entrada com a saída conhecida, criando uma relação entre ambos. Posteriormente, o algoritmo treinado tem a tarefa de prever a saída para novos dados de entrada desconhecidos. Os algoritmos supervisionados utilizados para previsões categóricas ou numéricas, sendo então conhecidos como algoritmos de classificação e regressão, respectivamente. Por sua vez, os algoritmos de aprendizado não supervisionados recebem os dados de entrada não identificados. Com isso, o algoritmo agrupa dados similares, identificando padrões dentro dos dados de entrada. Por fim, os algoritmos de aprendizado por reforço são algoritmos que aprendem por meio de recompensa ou penalidade após tomarem suas decisões de predição dos dados. Exemplos de algoritmos de ML dentro dessas categorias podem ser observados na Figura 9.




Figura 9. Categorização de algoritmos de ML.

2.4.1 Redes Neurais Artificiais

O cérebro humano é composto por bilhões de neurônios que estão interconectados entre si e processam todas as informações que recebemos. Observando essa característica, as redes neurais artificiais, ou *Artificial Neural Networks* (ANN), inspiram-se neste comportamento cerebral, sendo capaz de emular funções complexas, tais como a geração de padrões, aprendizado e tomada de decisões.

As redes neurais artificiais apresentam uma estrutura similar das redes neurais biológicas, com um modelo simplificado. Essas redes são compostas por camadas de neurônios, ou nós, interconectadas entre si. Inicialmente, a camada de entrada é responsável pelo recebimento das informações. Posteriormente, encontram-se as camadas internas de processamento da rede. As informações que percorrem pelos nós das camadas internas da rede são ponderados por um peso, aplicado individualmente para cada ligação entre os nós da rede. Por fim, encontra-se a camada de saída, a qual converge o resultado do processamento das informações da rede.

Cada ANN possui uma configuração de nós e camadas de acordo com os dados de entrada e o tipo de problema a ser resolvido. Um exemplo de um modelo simplificado de uma rede neural com duas camadas internas de processamento pode ser visualizado na Figura 10.




Figura 10. Composição típica de uma rede neural com duas camadas.

Para os algoritmos de aprendizado baseado em ANNs com duas ou mais camadas, atribui-se o termo *deep learning* (DL). Esse termo é utilizado para expressar redes neurais com maior "profundidade", capazes de identificar um número maior de características comportamentais dos dados de entrada [61].

Com isso, uma grande vantagem que redes de DL possuem em frente às redes convencionais de ANN são, por exemplo, a capacidade de identificar automaticamente atributos a partir dos dados de entrada, resolver problemas complexos de modo satisfatório e

rápido, permitir a construção de modelos complexos, possibilitar a computação paralela dos modelos, entre outros [62].

2.4.2 TensorFlow

TensorFlow é um *framework* de código aberto desenvolvido por pesquisadores da Google LLC para processar algoritmos de *machine learning* e *deep learning*, dentre outros modelos estatísticos e preditivos. Assim como outras plataformas similares, seu propósito é agilizar o processo de desenvolvimento e execução de aplicações analíticas avançadas para cientistas de dados, estatísticos, dentre outros [63].

Essa ferramenta é capaz de manipular conjuntos de dados em formatos de matrizes como nós computacionais em formato de grafo. As bordas que conectam os nós em um grafo podem ser representadas por vetores ou matrizes multidimensionais, criando tensores. Assim, a arquitetura de fluxo de dados do Tensorflow, sobre resultados intermediários generalizados de computação, permite o processamento paralelo em larga escala de várias aplicações, tais como redes neurais ([63] e [64]).

2.4.2.1 TensorFlow Lite

O TensorFlow Lite é um conjunto de ferramentas para machine learning no dispositivo que ajuda os desenvolvedores a executar modelos em dispositivos móveis, embarcados e de IoT [65]. Seus principais atributos são:

- Otimização para algoritmos de *machine learning* em dispositivos, com foco em 5 (cinco) limitações: latência (sem necessidade de troca de informações com servidores); privacidade (nenhum dado pessoal sai do dispositivo); conectividade (sem necessidade de conexão com a Internet); tamanho (modelo binário reduzido); consumo de energia (inferência eficiente, sem a necessidade de conexões com demais redes).
- Suporte a múltiplas plataformas, atendendo dispositivos Android, iOS, embarcados com Linux e microcontroladores.
- Suporte a diversas linguagens de programação, tais como Java, Swift, C++, Python e Flutter.
- Alta performance, com aceleração de *hardware* e otimização de modelos.

Com isso, os modelos para a versão do Tensorflow Lite são convertidos em arquivos binários, onde o seu resultante atinge no máximo o valor de aproximadamente 1 MB

quando todos os seus operadores suportados são utilizados. Por exemplo, modelos de classificação como InceptionV3 e MobileNet requerem apenas cerca de 300 kB para suportar seus operadores necessários [65].

O processo para uma aplicação utilizando o *framework* Tensorflow Lite pode ser conferido na Figura 11.




Figura 11. Diagrama de utilização do *framework* Tensorflow Lite [66].

3. MATERIAL E MÉTODOS

3.1 AMOSTRAS DE TRIGO

Para o presente trabalho, selecionam-se dois conjuntos de amostras de trigo. O primeiro conjunto tem por objetivo o treinamento e testes do algoritmo de *machine learning*. O segundo conjunto de amostras é segmentado para a validação do sistema.

Ambos conjuntos de amostras são compostos por grãos de trigos comerciais, colhidos em ponto de maturidade, nos anos de 2020 e 2021. O local de plantio de colheita dos grãos de trigo é a região do Alto Uruguai, no estado do Rio Grande do Sul, Brasil.

O primeiro conjunto é composto por 47 (quarenta e sete) amostras de grãos contaminados com a micotoxina DON, de 307 $\mu\text{g/kg}$ a 3757 $\mu\text{g/kg}$, e 42 (quarenta e duas) amostras de grãos saudios. O segundo conjunto é composto por 75 (setenta e cinco) amostras de grãos contaminados com a micotoxina DON, de 307 $\mu\text{g/kg}$ a 5078 $\mu\text{g/kg}$, e 42 (quarenta e duas) amostras de grãos saudios. Parte do conjunto de amostras utilizada no respectivo trabalho é apresentado na Figura 12.




Figura 12. Amostras de trigo.

As concentrações dos níveis de DON em ambos conjuntos de amostras foram aferidas pelo método DC-ELISA (Direct Competitive Enzyme Linked Immunosorbent Assay). A seleção, separação e realização da aferição dos níveis de DON nas amostras de trigo foram realizadas pela equipe técnica da Embrapa Trigo, unidade de Passo Fundo.

3.2 HARDWARE

3.2.1 Sensor Multiespectral

A seleção para o sensor multiespectral a ser utilizado no presente trabalho fundamenta-se em duas condições: baixo custo para aquisição e operação dentro do espectro VIS-NIR. Para tal atividade seleciona-se o módulo AS7265x Smart Spectral Sensor (ams-OSRAM AG, Premstaetten, Austria) [67]. Esse módulo é composto por três sensores multiespectrais complementar entre si (AS72651, AS72652 e AS72653), comumente referidos como AS7265X, atingindo um alcance espectral de 410 nm até 940 nm. Uma imagem do sensor AS72651 é exposto na Figura 13.




Figura 13. Sensor multiespectral AS72651.

Esse sensor foi otimizado para capturar luz difusa, logo, caso a fonte de luz for pontual ou direta, deve-se utilizar um difusor para criar uma superfície lambertiana com características acromáticas. O campo de alcance do sensor pode ser visualizado na Figura 14(a). Adicionalmente, a janela de captura espectral para cada banda do sensor é de 20 nm, representada na Figura 14(b).




Figura 14. Características ópticas dos sensores AS7265X.

O sensor AS72651 atua como mestre do conjunto, disponibilizando periféricos de comunicação com a unidade de controle via I2C ou Serial e comunicação com os demais sensores (AS72652 e AS72653) via I2C. Esse sensor também embarca uma interface SPI para carregar os dados uma memória flash contendo o *firmware* de operação para o módulo. Adicionalmente, todos os três sensores embarcam um cristal oscilador de 16 MHz para controle do seu clock de operação, sensor de temperatura e um controlador de iluminação LED. O diagrama de construção do módulo AS7265x com os três sensores e seus respectivos periféricos são demonstrados na Figura 15.




Figura 15. Diagrama do módulo AS7265X.

3.2.2 Montagem Eletrônica

Para a montagem eletrônica do sensor AS7265x escolheu-se o módulo de desenvolvimento disponibilizado pelo fabricante do sensor, o AS7265X DEMO KIT. Esse módulo de desenvolvimento contempla a montagem dos três sensores (AS72651, AS72652 e AS72653) em uma placa eletrônica, local para soldagem dos LEDs acionados por cada sensor, posicionados ao lado dos mesmos, um regulador de tensão para alimentação do conjunto eletrônico e um conector USB para comunicação serial com os sensores. Uma imagem módulo de desenvolvimento é demonstrado na Figura 16.




Figura 16. Módulo de desenvolvimento AS7265X DEV MODULE.

3.2.3 Sistema de Iluminação

A fonte de iluminação utilizada em tecnologias baseadas em espectroscopia possui importância fundamental no processo de análise do comportamento das amostras. Partindo do princípio que os sensores devem captar a luz refletida pelas amostras, os comprimentos de onda utilizados pelo sistema de iluminação devem abranger todo o espectro analisado.


O método utilizado para esse sistema baseia-se na escolha de um conjunto de LEDs de alta potência que contemplem o espectro de interesse da pesquisa. Os mesmos devem ser instalados ao lado dos sensores, no módulo de desenvolvimento, e acionados por eles.

Para isso, escolhe-se o conjunto de LEDs Lumileds L1SP-FRD0002800000, Lumileds L1SP-PNK1002800000 e Everlight SIR67-21C/TR8. Dessa forma, o conjunto de iluminação resultante tem um alcance espectral de 410 nm a 940 nm. As curvas dos LEDs escolhidos são demonstradas na Figura 17.


3.2.4 Montagem Mecânica

Um conjunto de peças mecânicas se faz necessário para acomodar as partes eletrônicas, assim como as amostras de grãos de trigo. Essa montagem deve permitir a leitura espectral enquanto o sistema de iluminação é acionado. Pretende-se também, a partir dessa montagem, impedir que a luz externa interfira na leitura das amostras, uma vez que deseja-se estabelecer um padrão de controle sobre o espectro analisado das amostras.

Um esboço construtivo da montagem mecânica do dispositivo é apresentado na Figura 18. Ao topo, encontra-se a placa eletrônica de desenvolvimento AS7265X DEMO



(a) L1SP-PNK1002800000 (Horticulture White) e L1SP-FRD0002800000 (Far Red).



(b) SIR67-21C/TR8.

Figura 17. Curvas da resposta espectral dos LEDs L1SP-PNK1002800000, L1SP-FRD0002800000 e SIR67-21C/TR8.

KIT. Fixada a ela, ao centro, estão os sensores multiespectrais e os LEDs de iluminação. Às bordas dos sensores e LEDs instala-se uma isolamento a fim de garantir a não entrada de luz externa durante o processo de leitura das amostras. Fixado a isso, está uma peça de cobertura, a qual deve direcionar a iluminação. A cobertura deve-se encaixar em uma base, onde depositam-se as amostras de grão de trigo.




Figura 18. Esboço da montagem mecânica do dispositivo de leitura multiespectral.

A fim da execução das peças mecânicas apresentadas no diagrama superior, busca-se a tecnologia de impressão 3D. Com o auxílio do programa FreeCAD 3D, desenham-se três peças que compõem a estrutura planejada. As peças desenvolvidas são demonstradas na Figura 19. A cobertura é separada em duas peças, uma tampa e um anel para encaixe com o sensor e os LEDs.




Figura 19. Desenho técnico das peças impressas 3D.

A impressora Cliever CL2 3D é utilizada para a impressão do material. A mesma é abastecida com um filamento cinza em PLA (ácido polilático). Os materiais impressos são apresentados na Figura 20.




Figura 20. Peças impressas 3D.

Por fim, a montagem mecânica do dispositivo é finalizada com a instalação da placa eletrônica de desenvolvimento utilizando quatro hastes de fixação. Nas juntas entre a placa eletrônica e demais peças aplica-se um material isolante com base plástica. A montagem do dispositivo é demonstrada na Figura 21.

3.2.5 Calibração

Mudanças de temperatura e de alimentação podem alterar a performance do sistema multiespectral proposto. A fim de garantir uma operação estabilizada, adota-se um processo de calibração utilizando um padrão branco de referência. Dessa forma, previamente às leituras do sensor sobre as amostras, realiza-se a leitura de uma peça conhecida, a fim de verificar e corrigir a resposta espectral.




Figura 21. Montagem do dispositivo.

Para isso, escolhe-se o PTFE (politetrafluoretileno), um fluoro-polímero sintético mais conhecido por seu nome comercial, Teflon. Esse material possui alta reflectância difusa sobre o espectro VIS-NIR. Uma folha de PTFE com 20 mm de espessura, o recorte da peça utilizada para o método de calibração e a peça inserida na base para leitura espectral são demonstrados na Figura 22.




Figura 22. Peças de calibração.

3.2.6 Dispositivo Móvel

Para o presente trabalho, define-se um dispositivo móvel para alimentação do sistema espectral e processamento das informações. Esse dispositivo deve possuir uma especificação básica de um dispositivo móvel capaz de execução de aplicações atuais de mercado. Para isso, o dispositivo Samsung Galaxy A10s (SM-A107M/DS) é selecionado, juntamente com o sistema operacional Android 10. Esse dispositivo móvel dispõem de um

processador de 8 (oito) núcleos de 2 GHz, com chipset Helio P22 MediaTek MT6762. Sua GPU é de modelo PowerVR GE8320 e sua memória RAM contempla 2 GB.

O dispositivo dispõe de uma porta de conexão micro USB, a qual é conectada um adaptador USB OTG (On the Go) e um conversor USB-Serial. O material utilizado para conexão entre o dispositivo móvel e o dispositivo de leitura multiespectral podem ser visualizados a partir da Figura 23.



Figura 23. Cabo de conexão USB OTG e conversor USB-Serial.

O conversor USB-Serial realiza a interface de conexão de dados do padrão USB para Serial, tornando assim possível a direta comunicação entre o dispositivo móvel e o grupo de sensores multiespectrais. Tal comunicação é realizada por meio da protocolo de transferência de dados UART (*Universal Asynchronous Receiver / Transmitter*) e protocolo de comandos/respostas conforme estabelecido pelo fabricante dos sensores, disponível para consulta na folha de dados do sensor. O protocolo UART via conversor USB-Serial está disponível para demais dispositivos Android de versão 4.3 ou superior.

3.3 SOFTWARE

3.3.1 TensorFlow

Para o desenvolvimento da aplicação de *machine learning* proposto no trabalho, utilizou-se do *framework* TensorFlow em sua versão 2.10.0 conforme disposto em [68]. Este *framework* contempla duas bibliotecas essenciais para o desenvolvimento do sistema proposto: Keras e TensorFlow Lite.

Inicialmente, a biblioteca Keras disponibiliza uma API (*Application Programming Interface*) escrita em Python para algoritmos de redes neurais de alto nível. Além de ser *open-source*, essa biblioteca é desenvolvida para possibilitar rápidas experimentações e modelagem das redes neurais.

Por fim, a biblioteca TensorFlow Lite é uma biblioteca para a implantação de modelos de *machine learning* desenvolvidos com o *framework* TensorFlow para dispositivos móveis, de borda, microcontroladores, entre outros.

3.3.2 Algoritmo ANN

Inspirado no sistema nervoso biológico, as Redes Neurais Artificiais, ou *Artificial Neural Networks* - ANN são algoritmos que representam um conjunto de neurônios (nós) conectados uns aos outros por meio de camadas. Em geral, as ANNs aprendem a realizar uma tarefa por meio de dados. Em uma rede de aprendizado supervisionado, um conjunto de dados de treinamento é composto por informações de entrada com saída conhecida. Durante o processo de aprendizado, diferentes pesos são dados a cada nó que compõem o sistema a fim de identificar diferentes padrões nas informações de entrada.

Uma ANN pode ser composta por uma camada de entrada, uma ou múltiplas camadas de processamento e uma camada de saída. Quanto maior o número de camadas de processamento inseridas ao modelo, maior o número de interconexões entre os nós que as compõem. Dessa forma, a informação de entrada percorre os nós, da entrada até a saída, com seu valor ponderado pelos pesos de cada nó obtido durante o processo de treinamento.

Para o presente trabalho, define-se o uso de duas ANNs devido sua capacidade de identificação de padrões, compatibilidade com a ferramenta TensorFlow, assim como suas APIs de elaboração Keras e TensorFlow Lite. A primeira ANN tem por objetivo uma identificação binária sobre a contaminação de DON nas amostras, sendo positiva ou negativa. A segunda ANN tem o propósito de identificar os níveis de contaminação a partir de um modelo de regressão. Utiliza-se

A partir da Tabela 3, pode-se conferir a composição de camadas, nós e método de ativação para as redes utilizadas.

3.3.3 Aplicação Mobile

Para o processamento dos dados coletados pelo sensor multiespectral e a mobilidade do sistema, desenvolve-se um aplicativo para o sistema operacional Android. Esse sistema operacional é selecionado por possuir código aberto e amplo suporte. Além disso,

Tabela 3. Composição das ANNs.

Modelo	Quantidade de Nós	Ativação
Binário	128	ReLU
	64	ReLU
	32	ReLU
	18	ReLU
	18	ReLU
	9	ReLU
	1	Sigmoid
Regressão	64	ReLU
	64	ReLU
	32	ReLU
	18	ReLU
	18	ReLU
	9	ReLU
	9	ReLU
	1	Nenhum

tem compatibilidade com dispositivos móveis de baixo custo, aumentando a aplicabilidade do sistema.

O aplicativo é desenvolvido em linguagem Dart, utilizando o SDK Flutter. Define-se o uso desta ferramenta devido a sua biblioteca *tflite_flutter*, a qual é capaz de processar os modelos de *machine learning* gerados a partir do *framework* TensorFlow com a biblioteca Keras e TensorFlow Lite.

O modelo de ANN é portado para o dispositivo móvel por meio do conversor TensorFlow Lite, o qual converte o modelo padrão de extensão *tf* para sua versão móvel, de extensão *tflite*. Para o aplicativo, faz-se o uso da biblioteca *tflite_flutter* 0.9.0 para carregar o arquivo *tflite* convertido, onde dada as novas entradas, é realizado o cálculo do modelo que gera a respectiva saída.

Uma imagem do aplicativo desenvolvido em execução pode ser visualizado na Figura 24.

3.4 PROCEDIMENTO DE COLETA E PROCESSAMENTO DOS DADOS

Inicialmente, realiza-se a leitura da peça de PTFE utilizada como referência para calibração utilizando o sistema multiespectral. A partir dos dados espectrais coletados da peça, define-se o padrão de leitura de referência sob condições normais.

Com o padrão de referência estabelecido, previamente às leituras multiespectrais das amostras de trigo, deve-se instalar a peça de referência de calibração e realizar uma leitura para ajustes dos parâmetros dos sensores.




Figura 24. Aplicativo móvel para conexão com sistema multiespectral.

Após o processo de calibração, coleta-se 12 cm³ de grãos de trigo para cada amostra analisada. Dessa forma, a altura entre os grãos analisados para com os sensores multiespectrais e LEDs são padrão para todas as amostras.

Após a leitura, executa-se o algoritmo ANN carregado ao dispositivo móvel, onde o resultado é exibido em tela. Uma imagem do sistema para coleta e processamento dos dados multiespectrais é exposto na Figura 25.




Figura 25. Sistema de coleta e processamento de dados multiespectrais.

4. RESULTADOS E DISCUSSÕES

O presente trabalho tem por objetivo a identificação dos níveis de contaminação por DON em amostras de trigo. Para atingir esse objetivo, um sistema de sensoriamento multiespectral móvel com algoritmos de redes neurais artificiais é composto.

Os resultados a seguir exibem o desempenho desse sistema considerando a avaliação do uso de duas redes neurais artificiais, binária e de regressão, e a combinação das mesmas, a fim da identificação da contaminação dos grãos de trigo pela micotoxina DON.

As avaliações dos resultados são dadas a partir de gráficos de correlação linear e matrizes de confusão. Para os gráficos de correlação linear, busca-se uma aproximação dos valores analisados com a linha de referência. É apresentado a linha de referência a ser observada a partir da Figura 26. Para a análise do seu desempenho em termos quantitativos, observam-se os parâmetros R^2 , MSE (*Mean Squared Error*) e RMSE (*Mean Squared Error*).




Figura 26. Linha de referência para gráficos de correlação.

Por sua vez, as análises sobre os resultados binários, ou seja, amostras contaminadas e sadias, são efetuadas a partir de matrizes de confusão. As mesmas seguem as seguintes características, conforme a Figura 27.

Para a sua análise quantitativa, são elencados quatro indicadores. A partir destes, compara-se o desempenho de cada algoritmo para a identificação das amostras sadias e contaminadas pela micotoxina DON. Os indicadores analisados para determinação da performance dos algoritmos são: acurácia (ACC), precisão (PRC), revocação (RVC) e seletividade (SEL).

A acurácia apresenta o quanto o modelo apresentou de acerto sobre todas as previsões possíveis a ele aplicado. A Equação 3 expõem o cálculo para esse indicador.

$$ACC = \frac{VS + VC}{VS + FC + FS + VC} \quad (3)$$

		Previsto	
		Sadias Previstas	Contaminadas Previstas
Verdadeiro	Sadias	Amostras Verdadeiras Sadias VS	Amostras Falso Contaminadas FC
	Contaminadas	Amostras Falso Sadias FS	Amostras Verdadeiras Contaminadas VC

Figura 27. Matriz de confusão padrão para análise dos dados.

onde VS é a quantidade de amostras verdadeiramente sadias, VC é a quantidade de amostras verdadeiramente contaminadas, FC é a quantidade de amostras previstas falsamente como contaminadas e FS é a quantidade de amostras previstas falsamente como sadias.

A precisão demonstra a proporção de acerto para o modelo respectivo ao total de amostras contaminadas previstas. A Equação 4 apresenta o cálculo para esse indicador.

$$PRC = \frac{VC}{VC + FC} \quad (4)$$

De forma similar, a seletividade é o grau de acerto do modelo para o total de amostras previstas como sadias. Essa relação dá-se a partir da Equação 5.

$$SEL = \frac{VS}{VS + FC} \quad (5)$$

Por fim, considera-se a revocação como o grau de acerto do modelo para o total de amostras verdadeiramente contaminadas, ou seja, a taxa de verdadeiros positivos. Quanto maior o grau de revocação, menor a taxa de amostras contaminadas previstas falsamente como sadias. Essa relação dá-se a partir da Equação 6.

$$RVC = \frac{VC}{VC + FS} \quad (6)$$

4.1 TREINAMENTO E TESTE

O primeiro conjunto de amostras de grãos de trigo é separado para o treinamento dos algoritmos de ANN. Sabendo que o volume de grãos deve ser o mesmo durante todas as leituras multiespectrais, é extraído uma parcela 12 cm³ para cada amostra conforme o método estabelecido. Após o processo de calibração com a peça de PTFE de referência, a amostra de grãos são depositados na base do sistema de leitura multiespectral. Ao todo, são realizados 50 leituras sobre cada parcela das amostras. Entre cada leitura, misturam-se os grãos depositados na base a fim de obter um conjunto de leituras espectrais diferentes sobre a mesma amostra.

Após realizado o processo de leitura sobre cada parcela das amostras de treinamento, um total de 4450 leituras espectrais são agrupadas em um banco de dados. Utilizando o método supervisionado para treinamento dos algoritmos de ANN binário e regressão, utiliza-se uma razão de 70/30 para divisão dos dados de treinamento e teste respectivamente. A seleção das leituras espectrais para teste e treinamento se dá de forma aleatória para cada amostra. Dessa forma, obtêm-se 3115 leituras multiespectrais para treinamento e 1335 leituras para teste dos algoritmos de ANN.

Inicialmente realiza-se o processo de treinamento e teste sobre o algoritmo de regressão. Para a avaliação do desempenho utiliza-se duas abordagens. A primeira leva em consideração o desempenho do algoritmo na previsão de todas as leituras espectrais, de forma individual. A segunda avaliação realiza uma média do resultado da predição do algoritmo para cada amostra. A correlação entre o resultado da predição dos níveis de contaminação de DON para as amostras de teste pelo algoritmo de regressão para o total de leituras e a média das amostras de leituras é apresentado na Figura 28.


Os valores para o modelo de regressão considerando o total de leituras, assim como a média para cada amostra, são demonstrados na Tabela 4.

Tabela 4. Desempenho do algoritmo de regressão para amostras de teste.


Modelo	R ²	MSE	RMSE
Regressão - Total de Leituras	0,8942	0,0084	0,0917
Regressão - Média das Amostras	0,9571	0,0034	0,0584

Pôde-se observar que a média das leituras espectrais de cada amostra teve maior proximidade com o real nível de contaminação. A partir da Figura 29 pode-se avaliar a distribuição do erro absoluto para as leituras das amostras testadas.

Após a avaliação sobre o algoritmo de regressão, realiza-se o treinamento com a rede neural binária. O seu modelo neural possui em sua última camada uma função sigmoide, cujo propósito é direcionar saídas para 0 ou 1, onde 0 representa amostras sadias e 1 representa amostras contaminadas. Após o treinamento, apesar da função sigmoide, a saída prevista pelo algoritmo para algumas leituras espectrais oscila ligeiramente entre



(a) Leituras totais.



(b) Média das amostras.

Figura 28. Correlação entre valores de contaminação verdadeiros e preditos das amostras de teste para o modelo de regressão.




Figura 29. Distribuição do erro absoluto entre a previsão do algoritmo e o valor verdadeiro de contaminação nas amostras de teste.

0 e 1. Com isso, verifica-se a acurácia do modelo para diferentes limites de decisão entre amostras sadias e contaminadas.

Para a determinação do limite de decisão entre amostras sadias e contaminadas, realiza-se um teste verificando a acurácia obtida para diferentes limites. Com isso, limites variando entre 0,01 a 1, com passos de 0,01, são demonstrados na Figura 30.




Figura 30. Evolução da acurácia para amostras de teste para o modelo binário.

Ao analisar a performance dos diferentes limites, conforme exposto na Figura 30, observa-se que o limite de 0,05 apresenta melhor resultado. Com isso, as amostras de teste aplicadas à rede neural binária que apresentarem valores de 0,05 ou superiores são consideradas como contaminadas.

Tendo isso em mente, monta-se uma matriz de confusão para a classificação das amostras sadias e contaminadas de acordo com os dados reais e preditos pelo algoritmo. A matriz de confusão obtida pelo algoritmo é apresentada na Figura 31. Os resultados dos indicadores para a performance do modelo são expostos na Tabela 5.




Figura 31. Matriz de confusão para o teste de amostras com o algoritmo binário.

Tabela 5. Desempenho do algoritmo de binário para amostras de teste.

Modelo	<i>ACC</i>	<i>PRC</i>	<i>SEL</i>	<i>RVC</i>
Binário	0,981	0,986	0,976	0,979

Pôde-se observar que o tanto o algoritmo de rede neural de regressão quanto o binário obtiveram resultados satisfatórios para previsão da contaminação por DON em grãos de trigo.

4.2 VALIDAÇÃO

Uma vez tendo os modelos binário e de regressão treinados e testados, encaminhase para a validação do sistema proposto com o segundo conjunto de amostras. Esse conjunto de validação é composto por 75 (setenta e cinco) amostras de grãos de trigo contaminados com a micotoxina DON e 42 (quarenta e duas) amostras de grão de trigo sadias.

Utilizando o mesmo método de leitura do primeiro conjunto, efetuou-se 5 (cinco) diferente leituras para cada amostra. De mesma forma, os grãos de trigo depositados na base do conjunto espectral foram misturados entre cada leitura. Ao todo, efetuaram-se 585 leituras espectrais para as amostras de validação.

Inicialmente, avaliou-se o desempenho do modelo de regressão. Para tal modelo, comparou-se os resultados totais das previsões feitas para cada leitura, assim como a média das cinco leituras obtidas para cada amostra. Pode-se observar esses resultados na Figura 32.


A partir da Tabela 6, pode-se conferir os valores de R^2 , MSE e RMSE para o modelo de regressão considerando o total de leituras, assim como a média de leitura para cada amostra.

Tabela 6. Desempenho do algoritmo de regressão para amostras de validação.


Modelo	R^2	MSE	RMSE
Regressão - Total de Leituras	-0,7450	0,2414	0,4913
Regressão - Média das amostras	-0,5923	0,2202	0,4693

Embora parte das amostras tenham sido identificadas como contaminadas, pode-se considerar baixa correlação entre o grau de contaminação com a previsão apresentada pelo algoritmo de regressão para as amostras de validação.

Dessa forma, pôde-se observar uma maior dificuldade do modelo de regressão na interpretação dos níveis de contaminação por DON. Esse fator pode ocorrer devido a ruídos apresentados pelo sensor no processo de coleta. Conforme exposto em [69], uma folha de PTFE de menor espessura pode cobrir o sensor, atuando como um filtro e difundindo melhor a iluminação aos sensores eletromagnéticos montados.



(a) Leituras totais.



(b) Média das amostras.

Figura 32. Resultado do modelo ANN de regressão.

Outro fator a ser observado é o controle do ambiente onde as amostras são examinadas, assim como o grau de umidade das mesmas, conforme apresentado em [70]. Tendo em mente que as amostras obtidas tem origem comercial, as mesmas não tiveram tratamento para extração de umidade nos grãos. Com isso, alterações no ambiente de armazenamento durante as etapas de treinamento, teste e validação tem impacto no desempenho do sistema apresentado. Um controle melhor sobre o ambiente pode otimizar os resultados do sistema.

Uma vez observado que o modelo de regressão identificou contaminação das amostras, porém não no nível correto, adaptou-se o resultado do modelo para uma resposta binária e avaliou-se seu desempenho em conjunto com o modelo binário. Para isso, o limite na decisão entre amostras sadias e contaminadas aplicado para o algoritmo foi de 0,05.

Também, realizou-se uma nova avaliação utilizando a combinação dos resultados do algoritmo binário e de regressão. A partir dessa combinação, a previsão obtida pelo algoritmo é considerada contaminada caso o algoritmo binário ou de regressão preverem dessa forma.

Com isso, as matrizes de confusão para os modelos analisados são demonstrados na Figura 33.




Figura 33. Resultado do modelo ANN de regressão.

Por fim, os indicadores de desempenho para os algoritmos de avaliação binária entre amostras sadias e contaminadas são apresentados na Tabela 7.

Tabela 7. Desempenho do algoritmo de binário em conjunto com o de regressão para amostras de validação.

Modelo	<i>ACC</i>	<i>PRC</i>	<i>SEL</i>	<i>RVC</i>
Binário - Total de Leituras	0,520	0,927	0,425	0,272
Regressão - Total de Leituras	0,631	0,873	0,492	0,496
Binário + Regressão - Total de Leituras	0,656	0,875	0,512	0,541
Binário - Média das amostras	0,769	0,944	0,619	0,680
Regressão - Média das amostras	0,838	0,868	0,780	0,880
Binário + Regressão - Média das amostras	0,855	0,872	0,820	0,906

Ao avaliar os resultados, pode-se identificar que ambos os modelos obtiveram um bom desempenho de precisão (*PRC*) para o total de leituras. Ou seja, os algoritmos foram capazes de apresentar um número menor de falsos positivos. Contudo, ao realizar a média das leituras, quando uma delas apresentou contaminação e a média ficou acima do limite estabelecido, a amostra foi identificada como contaminada. Assim sendo, a performance desse indicador decaiu ao realizar a média das leituras espectrais.

Por outro lado, a revocação (*RVC*), que demonstra os falsos negativos, teve baixa performance para a análise total das leituras espectrais. A partir da avaliação da média de leituras, pôde-se observar que esse indicador cresceu. Isso demonstra que das 5 (cinco) leituras efetuadas, ao menos um dentre elas apontou a amostra como contaminada. A combinação dos métodos, avaliando a média das leituras, trouxe o modelo com menor indicador de falso negativo.

A seletividade (*SEL*), seguindo o mesmo sentido que a revocação, teve seu desempenho otimizado conforme utilizou-se da média das leituras espectrais e combinação dos modelos.

A acurácia (*ACC*), que apresenta um critério sobre o comportamento geral dos modelos, também teve seu desempenho aprimorado com a identificação da contaminação por DON de acordo com a média das leituras e combinação dos modelos de ANN.

A banda espectral analisada para ambos algoritmos dada pelo sensor foi de 410nm a 940 nm. Segundo a pesquisa apresentada em [14], os autores analisaram extensivamente as respostas espectrais nas bandas de 528 nm a 1785 nm, com resolução de 5-7 nm, resultando em um total de 256 faixas de onda eletromagnéticas. Nisso, os autores identificaram as bandas de 623 nm e 1411 nm com a maior correlação com o grau de contaminação das amostras por DON. O sistema utilizado nesse estudo foi capaz de identificar a resposta espectral das amostras acerca da banda de 623 nm, contudo não possui alcance para 1411 nm. Uma implementação futura de um sensor específico adicional ao conjunto para captar bandas de maior comprimento pode auxiliar no desempenho do sistema.

Por sua vez, [71] realizou um estudo sobre a identificação de DON em grãos de trigo utilizando imagens hiper-espectrais e algoritmos de ML. Em seu estudo, os autores analisaram o espectro de 400 nm a 1000 nm, similar o proposto nesse trabalho, para

amostras com níveis de contaminação de 250–5000 $\mu\text{g/kg}$. Os autores testaram diferentes métodos para estimar os níveis de contaminação por DON e, para cada método, um grupo diferente de ondas eletromagnéticas foram selecionados. Com isso, na sua melhor combinação, os autores obtiveram uma precisão de 100 % e 97,72% para seus dados de treinamento e teste respectivamente. Por meio das imagens apresentadas pelos autores, é possível identificar que a distribuição da micotoxina nas amostras não é uniforme. Com isso, um numero maior de leituras das amostras se faz necessário para compensar o menor volume de dados em sensores multiespectrais, tais como utilizados nesse trabalho.

Além disso, verificou-se que a diferente composição das redes neurais tiveram uma característica operacional diferente. Cada rede neural foi capaz de identificar contaminação por DON em diferentes grupos de amostras. Conforme apresentado na Figura 33(b), a previsão sobre a média resultante do algoritmo binário teve o melhor desempenho para falsos positivos. Contudo, seu desempenho em falsos negativos foi o menor dentre todas as validações realizadas. Ao combinar seu resultado com a média das leituras do algoritmo de regressão, o número de amostras identificadas como falsos negativos reduziu significativamente. Em contra partida, o algoritmo de regressão trouxe o seu número de falsos positivos para o resultado final combinado. Por fim a acurácia do modelo combinado teve o melhor resultado dentre todos os métodos avaliados.

As redes neurais aplicadas para ambos algoritmos foram compostas por diversas camadas internas de neuros para treinamento. Uma melhoria a ser aplicada a esse sistema é a inserção de camadas de convolução no início da rede para obtenção de características, conforme apresentado em [72].

Outra melhoria que o sistema pode receber é a alimentação via baterias e comunicação WiFi conforme apresentado por [73]. Utilizando modos específicos de baixo consumo de energia e um microchip dedicado, o sistema proposto pode ser adaptado para operar de forma autônoma para a coleta de dados espectrais e enviar as informações para um dispositivo móvel ou servidor para análise.

5. CONCLUSÕES E TRABALHOS FUTUROS

Este trabalho apresentou uma abordagem a partir de sensores multiespectrais para a identificação da micotoxina desoxinivalenol em grãos de trigo utilizando algoritmos de *machine learning* em dispositivos móveis. A micotoxina desoxinivalenol, embora presente em baixas quantidades nos grãos de trigo, foi identificada por sensores multiespectrais dentro do espectro visível e infra-vermelho próximo. Isso vem de encontro ao encontrado na literatura, porém este trabalho traz uma abordagem diferente aos previamente investigados, seguindo a evolução do uso de dispositivos portáteis e de baixo custo, com aplicações dedicadas. O trabalho fez uso de tecnologias recentes e em crescente desenvolvimento, aplicando técnicas de *machine learning* em dispositivos móveis, com performance operacional podendo ser aplicadas em campo.

Dois modelos de redes neurais foram desenvolvidos, um modelo de regressão e um modelo binário. O modelo de regressão teve por objetivo identificar os níveis de contaminação e posteriormente foi adaptado para trabalhar em conjunto com o modelo binário para otimizar o desempenho do sistema proposto. Para este estudo foram separados dois conjuntos de amostras, um para treinamento e teste dos modelos, e um para validação. O resultado do processo de treinamento e teste dos modelos apresentou alta correlação para o modelo de regressão e alta acurácia para o modelo binário. Contudo, as validações no segundo conjunto de amostras não obtiveram os mesmos níveis de desempenho. A partir da adaptação da interpretação sobre as leituras espectrais de validação e a combinação de modelos, obteve-se um resultado satisfatório para a identificação da micotoxina.

Como trabalhos futuros, são sugeridas as seguintes considerações: realizar uma revisão sistemática sobre o uso de dispositivos multiespectrais para identificação de micotoxinas; utilizar um número maior de amostras de grãos de trigo, controlando variáveis de ambiente de temperatura e umidade, aplicando mais modelos de *machine learning* para comparação de desempenho; aprimoramento do dispositivo multiespectral com a comparação de diferentes conjuntos de LEDs e aplicação de difusor em PTFE para os sensores espectrais; aplicação de outros sensores espectrais para leituras na faixa espectral de 1000 nm à 1600 nm para a identificação da micotoxina; desenvolvimento de um sistema com microcontrolador e bateria para tornar o dispositivo independente de *smartphones*; realização de uma revisão sistemática sobre os equipamentos dedicados e miniaturizados espectrais a fim de assimilar todas as novas abordagens e tecnologias empregadas para identificação de componentes sobre amostras de diversas origens.

REFERÊNCIAS BIBLIOGRÁFICAS

- [1] KANT, P. et al. Disease resistance. In: *Comprehensive Biotechnology*. Guelph, ON, Canada: Elsevier, 2019. cap. 4.59, p. 729–743.
- [2] SMEESTERS, L. et al. Non-destructive detection of mycotoxins in maize kernels using diffuse reflectance spectroscopy. *Food Control*, v. 70, p. 48–57, 2016.
- [3] European Commission. *Commission Regulation (EC) No 1881/2006 of 19 December 2006 setting maximum levels for certain contaminants in foodstuffs (Text with EEA relevance)*. 2006. Disponível em: <<https://eur-lex.europa.eu/legal-content/EN/TXT/PDF/?uri=CELEX:32006R1881&from=EN>>. Acesso em: Set. 06, 2022.
- [4] Diretoria Colegiada da Agência Nacional de Vigilância Sanitária. *RESOLUÇÃO - RDC N 138, DE 8 DE FEVEREIRO DE 2017*. 2017. Disponível em: <https://www.in.gov.br/materia/-/asset_publisher/Kujrw0TZC2Mb/content/id/20794568/do1-2017-02-09-resolucao-rdc-n-138-de-8-de-fevereiro-de-2017-20794496>. Acesso em: Set. 06, 2022.
- [5] TAHOUN, I. F. et al. Development and validation of a reliable lc-ms/ms method for simultaneous determination of deoxynivalenol and t-2 toxin in maize and oats. *Microchemical Journal*, v. 169, 2021.
- [6] PALACIOS, S. A. et al. Fusarium cerealis causing fusarium head blight of durum wheat and its associated mycotoxins. *International Journal of Food Microbiology*, v. 346, 2021.
- [7] MAGALLANES LÓPEZ, A. M. et al. Gluten extraction from deoxynivalenol contaminated wheat by wet milling. *Food Control*, v. 120, 2021.
- [8] DRAKOPOULOS, D. et al. Prevention of fusarium head blight infection and mycotoxins in wheat with cut-and-carry biofumigation and botanicals. *Field Crops Research*, v. 246, 2020.
- [9] ZAREEF, M. et al. Recent advances in assessing qualitative and quantitative aspects of cereals using nondestructive techniques: A review. *Trends in Food Science & Technology*, v. 116, p. 815–828, 2021.
- [10] QU, J. H. et al. Applications of Near-infrared Spectroscopy in Food Safety Evaluation and Control: A Review of Recent Research Advances. *Critical Reviews in Food Science and Nutrition*, v. 55, n. 13, p. 1939–1954, 2015.
- [11] GIROLAMO, A. D. et al. Fourier transform near-infrared and mid-infrared spectroscopy as efficient tools for rapid screening of deoxynivalenol contamination in wheat bran. *Journal of the Science of Food and Agriculture*, v. 99, p. 1946–1953, 2019.


- [12] RAPID and nondestructive quantification of deoxynivalenol in individual wheat kernels using near-infrared hyperspectral imaging and chemometrics. *Food Control*, v. 131, 2022.
- [13] LIMA, A.; BAKKER, J. Espectroscopia no infravermelho próximo para a monitorização da perfusão tecidual. *Revista Brasileira de Terapia Intensiva*, v. 23, n. 3, p. 341–351, 2011.
- [14] BARBEDO, J. G. A.; TIBOLA, C. S.; LIMA, M. I. P. Deoxynivalenol screening in wheat kernels using hyperspectral imaging. *Biosystems Engineering*, v. 155, p. 24–32, 2017.
- [15] FEMENIAS, A. et al. Use of hyperspectral imaging as a tool for Fusarium and deoxynivalenol risk management in cereals: A review. *Food Control*, v. 108, 2020.
- [16] DELWICHE, S. R.; BAEK, I.; KIM, M. S. Does spatial region of interest (roi) matter in multispectral and hyperspectral imaging of segmented wheat kernels? *Biosystems Engineering*, v. 212, p. 106–114, 2021.
- [17] ABITRIGO. *HISTÓRIA DO TRIGO*. 2022. Disponível em: <<https://www.abitrigo.com.br/conhecimento/historia-do-trigo/>>. Acesso em: Mai. 14, 2022.
- [18] TÔSTO, S. G. et al. *Aspectos geoespaciais da produção de trigo*. Campinas, SP: Embrapa Monitoramento por Satélite, 2013. 24 p.
- [19] UNITED STATES DEPARTMENT OF AGRICULTURE. *World agricultural production*. Palo Alto, CA, USA, 2022. Disponível em: <<http://www.hpl.hp.com/techreports/2005/HPL-2005-6R1.html>>.
- [20] SOARES, F. m. S. *Análise Mensal - Trigo*. Brasília, DF, 2022.
- [21] CEPEA. *Trigo - Análise conjuntural - Análise CEPEA*. São Paulo, SP, 2021.
- [22] SOUZA, R. G. de; FILHO, J. E. R. V. Produção de Trigo no Brasil: indicadores regionais e políticas públicas. *Texto para Discussão*, p. 1–41, 2020.
- [23] TIBOLA, C. S.; MIRANDA, M. Z. de; Marsalo Júnior, A. L. Perdas qualitativas e quantitativas no armazenamento de trigo. In: JÚNIOR, P. C. M.; NETO, S. A. dos R. (Ed.). *Perdas em transporte e armazenagem de grãos: panorama atual e perspectivas*. Brasília, DF, Brasil: Conab, 2021. cap. 4, p. 142–147.
- [24] MESTERHÁZY, á.; OLÁH, J.; POPP, J. Losses in the grain supply chain: Causes and solutions. *Sustainability (Switzerland)*, v. 12, n. 6, p. 1–18, 2020.
- [25] LAU, D. et al. *Embrapa-Principais doenças do trigo no sul do Brasil: diagnóstico e manejo*. Passo Fundo, RS, Brasil, 2020.
- [26] ISMAIEL, A. A.; PAPENBROCK, J. Mycotoxins: Producing fungi and mechanisms of phytotoxicity. *Agriculture*, v. 5, n. 3, p. 493–537, 2015.

- [27] ZUCCOLOTTO, T. *Fungos e micotoxinas em alimentos e bebidas*. Curitiba, PR: Contentus, 2020. 118 p.
- [28] HORKY, P. et al. Nanoparticles as a solution for eliminating the risk of mycotoxins. *Nanomaterials*, v. 8, 2018.
- [29] BERTHILLER, F. et al. Masked mycotoxins: A review. *Molecular Nutrition and Food Research*, v. 57, p. 165–186, 2013.
- [30] ADEYEYE, S. A. O. Fungal mycotoxins in foods: A review. *Cogent Food and Agriculture*, Cogent, v. 2, n. 1, p. 1–11, 2016.
- [31] COMMISSION, E.; HEALTH, D.-G. for; SAFETY, F. *RASFF annual report 2020*. [S.l.]: Publications Office, 2021.
- [32] TIBOLA, C. S.; FERNANDES, J. M. C. Contaminação do trigo por micotoxinas. In: *Micotoxinas no trigo : estratégias de manejo para minimizar a contaminação*. Brasília, DF, Brasil: Embrapa, 2020. cap. 1, p. 11–22.
- [33] TIBOLA, C. S. et al. Gestão da qualidade do trigo na pós-colheita. In: PIRES, J. L. F.; VARGAS, L.; CUNHA, G. R. da (Ed.). *Trigo no Brasil: bases para produção competitiva e sustentável*. Passo Fundo, RS: Embrapa Trigo, 2011. cap. 16, p. 391–425.
- [34] PITT, J. I.; TANIWAKI, M. H.; COLE, M. B. Mycotoxin production in major crops as influenced by growing, harvesting, storage and processing, with emphasis on the achievement of Food Safety Objectives. *Food Control*, Elsevier Ltd, v. 32, n. 1, p. 205–215, 2013.
- [35] APS. *American Phytopathological Society*. 2003. Disponível em: <<https://www.apsnet.org/edcenter/disandpath/fungalasco/pdlessons/Pages/FusariumPort.aspx>>. Acesso em: Jun. 18, 2022.
- [36] NICOLLI, C. P.; ANDRADE, B. C. d.; TIBOLA, C. S. Espécies micotoxigênicas e as principais micotoxinas no trigo. In: *Micotoxinas no trigo : estratégias de manejo para minimizar a contaminação*. Brasília, DF, Brasil: Embrapa, 2020. cap. 2, p. 23–37.
- [37] BONNET, M. S. et al. Advances in deoxynivalenol toxicity mechanisms: The brain as a target. *Toxins*, v. 4, n. 11, p. 1120–1138, 2012.
- [38] SOBROVA, P. et al. Deoxynivalenol and its toxicity. *Interdisciplinary Toxicology*, v. 3, n. 3, p. 94–99, 2010.
- [39] GUTERRES, C. W.; SANTANA, F. M. Estratégias de manejo pré-colheita para reduzir contaminação do trigo por micotoxinas. In: *Micotoxinas no trigo : estratégias de manejo para minimizar a contaminação*. Brasília, DF, Brasil: Embrapa, 2020. cap. 3, p. 38–50.

- [40] SERWAY, R. A.; JEWETT, J. J. W. *Princípios de Física vol. 4 - Óptica e Física Moderna – Tradução da 5ª edição norte-americana*. São Paulo, SP: Cengage Learning Brasil, 2014. 342 p.
- [41] WENTWORTH, S. M. *Fundamentos de eletromagnetismo com aplicações em engenharia*. Rio de Janeiro, RJ: LTC, 2006. 380 p.
- [42] PAVIA, D. L. et al. *Introdução à espectroscopia*. São Paulo, SP: Cengage Learning Brasil, 2015. 716 p.
- [43] CHRISTIAN, G. D.; DASGUPTA, P. K.; SCHUG, K. A. *Analytical Chemistry*. Nova York, NY: Wiley, 2013. 848 p.
- [44] SKOOG, D. A.; HOLLER, F. J.; CROUCH, S. R. *Princípios De Análise Instrumental*. Porto Alegre, RS: Bookman, 2002. 968 p.
- [45] HERSCHEL, W. F. Experiments on the refrangibility of the invisible rays of the sun. *Transactions of the Royal Academy*, v. 90, p. 284–292, 1800. Disponível em: <<https://archive.org/stream/philtrans08733349/08733349#page/n0/mode/2up>>.
- [46] MCCLURE, W. F. 204 years of near infrared technology: 1800–2003. *Journal of Near Infrared Spectroscopy*, v. 11, n. 6, p. 487–518, 2003.
- [47] ASTM. *Standard Practice for Near Infrared Qualitative Analysis*. West Conshohocken, PA, USA, 2016. Disponível em: <<https://www.astm.org/e1790-04r16e01.html>>.
- [48] PASQUINI, C. Near infrared spectroscopy: A mature analytical technique with new perspectives – A review. *Analytica Chimica Acta*, v. 1026, p. 8–36, 2018.
- [49] BROUILLETTE, C. et al. Analysis of Twenty-Two Performance Properties of Diesel, Gasoline, and Jet Fuels Using a Field-Portable Near-Infrared (NIR) Analyzer. *Applied Spectroscopy*, v. 70, n. 5, p. 746–755, 2016.
- [50] LIMA, K. M. G. de. A portable photometer based on LED for the determination of aromatic hydrocarbons in water. *Microchemical Journal*, v. 103, p. 62–67, 2012.
- [51] GENTILIN, F. A. et al. Development and testing of a hardware platform for measuring instruments based on near-infrared diffuse reflection. *Measurement: Journal of the International Measurement Confederation*, v. 86, p. 14–25, 2016.
- [52] LIU, B.-M. et al. A high-efficiency blue-led-excitable nir-ii-emitting mgo:cr³⁺,ni²⁺ phosphor for future broadband light source toward multifunctional nir spectroscopy applications. *Chemical Engineering Journal*, v. 452, 2023.

- [53] VIGNADUZZO, S. E.; MAGGIO, R. M.; OLIVIERI, A. C. Why should the pharmaceutical industry claim for the implementation of second-order chemometric models—A critical review. *Journal of Pharmaceutical and Biomedical Analysis*, v. 179, 2020.
- [54] ACHATA, E. M. et al. Development of NIR-HSI and chemometrics process analytical technology for drying of beef jerky. *Innovative Food Science and Emerging Technologies*, v. 69, 2021.
- [55] SAHA, D.; MANICKAVASAGAN, A. Machine learning techniques for analysis of hyperspectral images to determine quality of food products: A review. *Current Research in Food Science*, v. 4, p. 28–44, 2021.
- [56] LIANG, K. et al. Comparison of Vis-NIR and SWIR hyperspectral imaging for the non-destructive detection of DON levels in Fusarium head blight wheat kernels and wheat flour. *Infrared Physics & Technology*, v. 106, 2020.
- [57] FU, Y. et al. Progress of hyperspectral data processing and modelling for cereal crop nitrogen monitoring. *Computers and Electronics in Agriculture*, v. 172, 2020.
- [58] SAMUEL, A. L. Some Studies in Machine Learning. *IBM Journal of Research and Development*, v. 3, n. 3, p. 210–229, 1959.
- [59] SHARMA, A. et al. Machine Learning Applications for Precision Agriculture: A Comprehensive Review. *IEEE Access*, v. 9, p. 4843–4873, 2021.
- [60] LIAKOS, K. G. et al. Machine learning in agriculture: A review. *Sensors (Switzerland)*, v. 18, n. 8, p. 1–29, 2018.
- [61] LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. *Nature*, v. 521, n. 7553, p. 436–444, 2015.
- [62] PAN, S. J.; YANG, Q. A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, IEEE, v. 22, n. 10, p. 1345–1359, 2010.
- [63] VAUGHAN, J. *TensorFlow*. 2018. Disponível em: <<https://www.techtarget.com/searchdatamanager>>. Acesso em: Dez. 12, 2022.
- [64] TENSORFLOW DEVELOPERS. *Introduction to TensorFlow*. 2022. Disponível em: <<https://www.tensorflow.org/learn>>. Acesso em: Dez. 12, 2022.
- [65] TENSORFLOW DEVELOPERS. *TensorFlow Lite*. 2022. Disponível em: <<https://www.tensorflow.org/lite/guide>>. Acesso em: Dez. 12, 2022.
- [66] TENSORFLOW DEVELOPERS. *Deploy machine learning models on mobile and edge devices*. 2022. Disponível em: <<https://www.tensorflow.org/lite>>. Acesso em: Dez. 12, 2022.

- [67] OSRAM GROUP. AS7265x. [S.l.], 2018. 63 p. Disponível em: <<http://www.opioids.com/morphine/morphine-avinza.pdf>>.
- [68] ABADI, M. et al. *TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems*. 2015. Disponível em: <<https://www.tensorflow.org/>>. Acesso em: Dez. 12, 2022.
- [69] BOTERO-VALENCIA, J. S.; MEJIA-HERRERA, M. Modular system for UV–vis-NIR radiation measurement with wireless communication. *HardwareX*, v. 10, 2021.
- [70] ZHENG, X. et al. Non-destructive prediction of moisture of wheat seed kernel by using VIS/NIR hyperspectral technology. *2016 American Society of Agricultural and Biological Engineers Annual International Meeting, ASABE 2016*, p. 10–16, 2016.
- [71] LIANG, K. et al. Determination and Visualization of Different Levels of Deoxynivalenol in Bulk Wheat Kernels by Hyperspectral Imaging. *Journal of Applied Spectroscopy*, v. 85, n. 5, p. 953–961, 2018.
- [72] HEYDAROV, S. et al. Low-cost VIS/NIR range hand-held and portable photospectrometer and evaluation of machine learning algorithms for classification performance. *Engineering Science and Technology, an International Journal*, v. 37, 2023.
- [73] BOTERO-VALENCIA, J. S.; VALENCIA-AGUIRRE, J. Portable low-cost IoT hyperspectral acquisition device for indoor/outdoor applications. *HardwareX*, v. 10, 2021.



UPF
UNIVERSIDADE
DE PASSO FUNDO

UPF Campus I - BR 285, São José
Passo Fundo - RS - CEP: 99052-900
(54) 3316 7000 - www.upf.br